

Classificação de Condições Maculares em Tomografia de Coerência Óptica com Descritores HOG e uma Rede Convolutacional Compacta

Jheam Storch Ross, Felipe Mattos Vanetti de Albuquerque e Gabriel Zuany Duarte Vargas

*Departamento de Informática
Universidade Federal do Espírito Santo
Vitória, Brasil*

I. INTRODUÇÃO

A mácula é a região central da retina responsável pela visão de detalhes. Alterações em sua estrutura podem comprometer de forma importante a visão central, mesmo quando a visão periférica permanece preservada. Este trabalho considera as quatro classes definidas no conjunto de dados de Kermany et al. [1]: neovascularização coroideana (CNV, do inglês *choroidal neovascularization*), edema macular diabético (DME, do inglês *diabetic macular edema*), drusas e retina normal. Elas não correspondem a quatro doenças: CNV é um processo patológico, drusas são achados anatômicos e a classe normal é uma referência. No contexto da base, a CNV é usada como representação da forma neovascular avançada da degeneração macular relacionada à idade (DMRI), caracterizada por membrana neovascular e possível fluido sub-retiniano. O DME decorre da retinopatia diabética e apresenta espessamento da retina associado ao acúmulo de fluido intrarretiniano. Drusas são depósitos lipídicos associados à forma seca ou inicial da DMRI. A classe normal apresenta contorno foveal preservado e ausência de edema ou fluido retiniano [1], [2].

A tomografia de coerência óptica (OCT, do inglês *optical coherence tomography*) é uma modalidade não invasiva e sem contato que emprega interferometria de baixa coerência para obter cortes ópticos de alta resolução dos tecidos [3], [4]. Durante o exame, o paciente mantém a fixação enquanto o equipamento realiza uma varredura luminosa da retina. Cada corte transversal é denominado B-scan, e uma sequência desses cortes pode compor uma representação volumétrica [4]. Em complemento ao exame clínico e à fotografia colorida de fundo de olho, a OCT permite observar separadamente as camadas retinianas e evidenciar fluido intrarretiniano ou sub-retiniano, que pode não ser claramente visível nessas outras modalidades [1]. Por isso, a OCT orienta a avaliação, o encaminhamento e o acompanhamento da resposta ao tratamento com agentes anti-VEGF (do inglês *anti-vascular endothelial growth factor*).

A Fig. 1 apresenta B-scans ilustrativos das quatro classes. A CNV e o DME podem produzir fluido e deformação das camadas, porém possuem mecanismos e padrões distintos; as drusas aparecem como elevações localizadas sob as camadas externas da retina; e a amostra normal preserva a depressão

foveal. A presença de fluido em mais de uma condição e as diferenças entre seus padrões tornam a classificação automática um problema não trivial.

II. MOTIVAÇÃO

A deficiência visual possui impacto relevante no Brasil. A Pesquisa Nacional de Saúde de 2019 estimou que 3,4% da população com dois anos ou mais tinha muita dificuldade ou não conseguia enxergar, totalizando 6,978 milhões de pessoas [6]. Esse indicador descreve a limitação visual autorreferida, mas não identifica suas causas e, portanto, não pode ser atribuído diretamente às condições estudadas neste trabalho. Evidência etiológica mais específica é fornecida pelo São Paulo Eye Study, realizado em uma região de renda baixa e média da cidade de São Paulo: foram examinados 3.678 participantes com 50 anos ou mais, dos quais 3.642 tiveram acuidade visual mensurável. Entre os 346 olhos com acuidade visual apresentada inferior a 20/200, doenças retinianas foram identificadas como causa principal em 35,3% [7]. Trata-se, contudo, de uma amostra regional, não de uma estimativa nacional.

O componente diabético também representa uma população de risco expressiva. Uma revisão sistemática com 72 estudos e 29.527 adultos com diabetes estimou prevalência de retinopatia diabética de 36,28% no Brasil, com intervalo de confiança de 95% entre 32,66% e 39,97% [8]. A heterogeneidade elevada ($I^2 = 98\%$) exige cautela, e retinopatia diabética não equivale especificamente a DME, que pode ou não estar presente. Para pacientes acima de 60 anos com DMRI neovascular, a incorporação de aflibercepte e ranibizumabe ao Sistema Único de Saúde em 2021 reforça a relevância de identificar e acompanhar alterações tratáveis em tempo adequado [2].

Como um exame pode conter diversos B-scans, a análise manual demanda tempo especializado. Sistemas automáticos podem apoiar a triagem e a priorização de exames para revisão especializada [1], [9]. Essa função deve ser entendida como suporte à decisão: uma imagem isolada não contém histórico clínico, exame físico, informações sobre tratamento ou todas as aquisições do volume. Além disso, um modelo treinado nessa base multicêntrica internacional não está validado para uso clínico na população brasileira.




Figura 1. Exemplos ilustrativos das quatro classes: (a) neovascularização coroideana, (b) edema macular diabético, (c) drusas e (d) retina normal. Foram usadas as imagens de treinamento CNV-1676918-1, DME-1083927-1, DRUSEN-3424668-17 e NORMAL-1001772-12, sem recorte ou alteração de conteúdo. Fonte: versão 3 do conjunto de Kermany et al., disponibilizada sob licença CC BY 4.0 [5].

Nesse contexto, o objetivo do projeto é investigar se uma rede neural convolucional compacta, treinada do zero, consegue aprender representações úteis das quatro classes e superar uma referência clássica baseada em descritores de histogramas de gradientes orientados (HOG, do inglês *histograms of oriented gradients*) e regressão logística. A comparação privilegia um protocolo reproduzível, com separação por paciente e relato conjunto de desempenho global e por classe. Foi utilizada a versão 3 do subconjunto OCT de Kermany et al. [5], preservando-se o conjunto de teste oficial. A validação foi amostrada somente do conjunto de treino, em proporção de 15%, por agrupamento dos identificadores de paciente extraídos de nomes no padrão Kermany, como CNV-1016042-1.jpeg. O manifesto final foi validado para garantir interseções vazias dos conjuntos de identificadores de paciente entre treino, validação e teste. O resultado pretendido é uma análise experimental de métodos de classificação, e não um dispositivo diagnóstico.

III. TRABALHOS RELACIONADOS

Srinivasan et al. [10] apresentaram um dos antecedentes mais próximos da abordagem clássica considerada neste projeto. O método extrai descritores HOG multiescala de cada B-scan e os fornece a classificadores de máquinas de vetores de suporte lineares; o rótulo do volume é determinado pela moda das previsões dos cortes. Em 45 sujeitos, divididos igualmente entre retina normal, DME e DMRI seca, o sistema identificou corretamente todos os volumes com DME e DMRI e 86,67% dos volumes normais. O número de classes, a escala da base e a avaliação por volume diferem do presente problema, impedindo comparação direta com acurácia por B-scan.

Kermany et al. [1] estabeleceram o benchmark de quatro classes utilizado neste trabalho. Os autores adaptaram uma Inception V3 pré-treinada no ImageNet, congelaram as camadas convolucionais e treinaram uma nova camada *softmax*.

A acurácia multiclasse relatada foi 96,6% em 1.000 imagens de 633 pacientes não presentes no treino. Já sensibilidade e especificidade de 97,8% e 97,4% foram calculadas para a decisão binária de encaminhamento urgente, não como médias das quatro classes; essas métricas não devem ser comparadas diretamente a *recall* macro ou AUC multiclasse.

Trabalhos posteriores questionaram a necessidade de redes profundas pré-treinadas para esse domínio. Butola et al. [11] propuseram a LightOCT, com duas camadas convolucionais e uma camada totalmente conectada, treinada do zero. Nas implementações comparativas dos próprios autores, avaliadas na partição de teste com 1.000 imagens, a LightOCT alcançou 94,5% de acurácia, próxima de VGG-19 (93,3%) e Inception V3 (95,8%), mas abaixo de ResNet-101 (96,7%). O artigo não descreve um conjunto de validação separado para essa base durante a exploração dos hiperparâmetros da LightOCT. Arefin et al. [12] também treinaram uma CNN sem transferência, formada por cinco camadas convolucionais e duas densas, e relataram 97,93% em 968 imagens de teste, uma partição posteriormente associada à versão 2 do conjunto [13].

Esses resultados precisam ser interpretados junto à análise de Tampu et al. [13]. Nos experimentos conduzidos pelos autores, separar B-scans sem respeitar sujeito ou volume inflou a acurácia entre 5 e 30 pontos percentuais, pois cortes consecutivos compartilham estruturas e ruído. Na versão 2 de Kermany, 92% das imagens de teste possuíam identificadores de sujeitos também presentes no treino; na versão 3, não foi encontrada sobreposição de identificadores. Assim, o valor de Arefin et al. e outros resultados obtidos na versão 2 não constituem referências equivalentes a uma avaliação sem sobreposição por paciente.

Em uma direção mais próxima da aplicação clínica, De Fauw et al. [9] combinaram uma U-Net tridimensional, que converte o volume em mapas de tecido, com uma rede de diagnóstico e recomendação de encaminhamento. Foram

usados 14.884 volumes de 7.621 pacientes, com teste em 997 pacientes. A coorte foi obtida de uma via clínica que abrangia mais de 50 condições retinianas. O sistema previa quatro níveis de encaminhamento e dez rótulos diagnósticos adicionais. Essa tarefa clínica é mais ampla que as quatro classes deste trabalho e seus resultados não são diretamente comparáveis. A Tabela I resume as diferenças centrais entre os estudos comparáveis.

Em conjunto, a literatura indica que arquiteturas compactas podem ser competitivas, mas não demonstra que transferência de aprendizado seja desnecessária em geral. Profundidade, número de parâmetros, versão da base, unidade de avaliação e estratégia de particionamento variam simultaneamente. Isso motiva a comparação controlada entre HOG e uma CNN compacta sob o mesmo manifesto com teste oficial preservado e separação validada por paciente, mantendo os experimentos exploratórios com transferência apenas como evidência secundária.

IV. METODOLOGIA

Esta seção descreve o protocolo experimental adotado na comparação entre os dois modelos. Inicialmente, apresentam-se o conjunto de dados e a divisão por paciente (Seção IV-A). Em seguida, descrevem-se os modelos comparados: a regressão logística sobre descritores HOG (Seção IV-B) e a rede convolucional compacta treinada do zero (Seção IV-C). Por fim, detalham-se as estratégias que compõem o treino, comuns a ambos os modelos ou específicas da rede convolucional, a saber, o aumento de dados (Seção IV-D), o tratamento do desbalanceamento de classes (Seção IV-E) e a configuração de otimização (Seção IV-F), além das métricas de avaliação (Seção IV-G).

A. Dados

Foi utilizada a versão 3 do subconjunto OCT do conjunto de Kermany et al. [5], formado por B-scans maculares em tons de cinza organizados nas quatro classes já apresentadas. O pacote é distribuído com uma divisão oficial entre treino e teste, sendo o teste composto por 1.000 imagens balanceadas, 250 por classe. Após a leitura das imagens e a remoção de duplicatas, o manifesto reúne 109.309 B-scans; a porção de radiografias de tórax incluída no pacote original não faz parte do escopo deste trabalho.

O conjunto de teste oficial foi preservado integralmente, sem qualquer reamostragem, para permitir comparação direta com os resultados relatados na literatura sobre a mesma partição. O conjunto de validação foi amostrado exclusivamente do treino, na proporção de 15%, por agrupamento dos identificadores de paciente inferidos dos nomes de arquivo no padrão Kermany, como CNV-1016042-1.jpeg. O agrupamento mantém todas as imagens de um mesmo paciente em um único conjunto, e o manifesto foi verificado para garantir interseção vazia de identificadores entre treino, validação e teste. Essa separação é essencial, pois dividir B-scans sem respeitar o paciente infla artificialmente o desempenho; a versão 3 é adequada a esse protocolo por não apresentar sobreposição de identificadores entre treino e teste [13].

A Tabela II detalha a distribuição por classe e conjunto. No treino, as classes são acentuadamente desbalanceadas: a retina normal e a CNV concentram a maior parte das amostras, enquanto drusas e DME são minoritárias. Esse desequilíbrio motiva o tratamento descrito na Seção IV-E. O teste oficial, ao contrário, é balanceado, com 250 imagens por classe, o que favorece a leitura das métricas globais discutidas na Seção IV-G.

B. Regressão logística com HOG

A abordagem clássica combina descritores HOG com um classificador linear. Cada B-scan é convertido para tons de cinza, redimensionado para 224×224 e descrito por HOG com 9 orientações, células de 16×16 pixels e blocos de 2×2 células. O descritor resume a distribuição local de orientações de gradiente, sensível aos contornos das camadas retinianas alteradas pelas condições estudadas. O vetor resultante é padronizado e classificado por regressão logística multinomial (solucionador *lbfgs*, limitado por 2.000 iterações), com o desbalanceamento tratado por ponderação de classes (Seção IV-E).

C. Rede Convolucional Compacta

A rede convolucional compacta é treinada do zero e aprende representações hierárquicas diretamente dos B-scans, sem transferência de aprendizado. A Tabela III apresenta sua arquitetura. As imagens, em tons de cinza, são representadas em três canais e redimensionadas para 224×224 . O extrator de características é formado por três blocos convolucionais, cada um com convolução 3×3 , normalização em lote, ativação ReLU e *max-pooling* 2×2 . A normalização em lote estabiliza o treino e a redução progressiva concentra a informação em mapas de características mais abstratos.

Em vez de camadas densas de grande porte, um *pooling* médio global condensa cada mapa de características em um único valor, o que reduz de forma acentuada o número de parâmetros e a propensão ao sobreajuste. O vetor de 128 dimensões passa por *dropout* ($p = 0,25$) e por uma camada linear com *softmax* sobre as quatro classes. O modelo totaliza cerca de 94 mil parâmetros, significativamente menor que a Inception V3 adotada por Kermany et al. [1], a qual possui aproximadamente 23 milhões. As estratégias de aumento de dados e de tratamento do desbalanceamento aplicadas a essa rede são descritas nas Seções IV-D e IV-E.

D. Aumento de dados

O aumento de dados é aplicado apenas ao conjunto de treino da rede convolucional; validação e teste não são alterados. Foram utilizadas duas transformações condizentes com a natureza dos B-scans: espelhamento horizontal ($p = 0,5$), que corresponde à simetria entre os lados nasal e temporal e à alternância entre olho direito e esquerdo, e rotação aleatória de até 5° , compatível com pequenas angulações no posicionamento do aparelho durante a aquisição. Ambas preservam a ordenação anatômica das camadas retinianas. Transformações que violariam essa ordenação foram evitadas: o espelhamento

Tabela I

SÍNTESE DOS TRABALHOS MAIS DIRETAMENTE RELACIONADOS. RESULTADOS DE PROTOCOLOS, VERSÕES E UNIDADES DE AVALIAÇÃO DIFERENTES NÃO FORMAM UM RANKING ÚNICO.

Estudo	Abordagem	Dados e avaliação	Resultado e ressalva
Srinivasan et al. [10]	HOG multiescala e SVM	45 sujeitos; normal, DME e DMRI seca; avaliação por volume	100% para DME/DMRI e 86,67% para normal; tarefa menor e distinta
Kermany et al. [1]	Inception V3/ImageNet; convoluções congeladas	108.312 imagens de treino; avaliação separada por paciente com 1.000 B-scans	96,6% de acurácia; sensibilidade/especificidade publicadas referem-se à decisão urgente
Butola et al. [11]	LightOCT com duas convoluções, treinada do zero	Quatro classes; teste oficial com 1.000 B-scans	94,5%; desempenho próximo das redes pré-treinadas nas implementações dos autores
Arefin et al. [12], [13]	CNN com cinco convoluções e duas camadas densas, sem transferência	Versão 2; teste oficial com 968 B-scans	97,9%; versão posteriormente associada a sobreposição entre treino e teste
Tampu et al. [13]	LightOCT sob diferentes estratégias de particionamento	Versões 2 e 3; divisão por imagem e por sujeito/volume	Inflação de 5–30 pontos percentuais; 92% das imagens de teste compartilhavam ID de sujeito com o treino na versão 2; nenhum ID compartilhado foi detectado na versão 3

Tabela II

DISTRIBUIÇÃO DE B-SCANS POR CLASSE E CONJUNTO NO MANIFESTO DA VERSÃO 3 DO SUBCONJUNTO OCT.

Classe	Treino	Validação	Teste	Total
CNV	32.014	5.191	250	37.455
DME	9.858	1.490	250	11.598
Drusas	7.408	1.208	250	8.866
Normal	43.907	7.233	250	51.390
Imagens	93.187	15.122	1.000	109.309
Pacientes	4.067	718	635	5.420

Tabela III

ARQUITETURA DA REDE CONVOLUCIONAL COMPACTA.

Camada	Configuração	Saída
Entrada	—	$3 \times 224 \times 224$
Conv+BN+ReLU	32 filtros 3×3	$32 \times 224 \times 224$
MaxPool	2×2	$32 \times 112 \times 112$
Conv+BN+ReLU	64 filtros 3×3	$64 \times 112 \times 112$
MaxPool	2×2	$64 \times 56 \times 56$
Conv+BN+ReLU	128 filtros 3×3	$128 \times 56 \times 56$
MaxPool	2×2	$128 \times 28 \times 28$
Pooling médio global	—	128
Dropout	$p = 0,25$	128
Linear + softmax	$128 \rightarrow 4$	4

vertical, por exemplo, inverteria a sequência das camadas, colocando a coróide acima do vítreo e produzindo uma imagem sem correspondência clínica.

E. Desbalanceamento de classes

Como mostra a Tabela II, o treino é desbalanceado, com razão de cerca de seis para um entre a classe mais e a menos frequente. Para evitar que as classes majoritárias dominem o aprendizado, ambos os modelos atribuem a cada classe uma importância inversamente proporcional à sua frequência, mas a aplicam de formas distintas. Na regressão logística, essa

importância entra na função de perda, fazendo com que erros em classes raras pesem mais no ajuste. Na rede convolucional, ela guia a amostragem: um amostrador aleatório ponderado sorteia as imagens de cada época com reposição, exibindo com mais frequência as classes minoritárias e tornando os *mini-batches* aproximadamente balanceados. Como essa reamostragem repete imagens minoritárias, é o aumento de dados (Seção IV-D) que introduz variação entre as repetições.

F. Treinamento

A regressão logística foi implementada com o Scikit-Learn e a rede convolucional compacta em PyTorch, com semente aleatória fixa em 42 para favorecer a reprodutibilidade. A regressão logística é ajustada em etapa única sobre os descritores HOG; o restante desta seção detalha o treino da rede convolucional. Antes de entrar na rede, cada imagem é redimensionada para 224×224 e normalizada com média e desvio-padrão de 0,5 por canal. A rede é otimizada com Adam, taxa de aprendizado inicial de 10^{-3} , minimizando a entropia cruzada em lotes de 32 imagens por até 50 épocas.

A taxa de aprendizado é reduzida por um fator de 0,2 quando a perda de validação não melhora por duas épocas consecutivas. O treino é interrompido antecipadamente após cinco épocas sem melhora dessa perda, e o modelo correspondente à menor perda de validação é retido para avaliação no conjunto de teste oficial.

G. Métricas de avaliação

O desempenho é reportado na Seção V por meio de precisão, *recall* e F1 para cada classe, além da média macro e da acurácia global. A média macro atribui o mesmo peso a todas as classes, independentemente de sua frequência; em particular, o *recall* macro equivale à acurácia balanceada. Reporta-se ainda a área sob a curva ROC (AUC, do inglês *area under the curve*) no esquema um-contra-o-resto, agregada por média macro, que resume a separabilidade das classes sem depender de um limiar de decisão. As matrizes de confusão, das quais derivam as métricas por classe, explicitam os padrões de erro entre as condições.




Figura 2. Curvas de perda de treino e validação da rede convolucional compacta.

V. RESULTADOS E DISCUSSÃO

A Fig. 2 apresenta as curvas de perda da rede convolucional. Ambas decrescem de forma consistente e se estabilizam a partir da décima terceira época, sem que a perda de validação volte a subir, o que caracteriza convergência sem *overfitting*. A oscilação das primeiras épocas decorre da taxa de aprendizado inicial e é atenuada após as primeiras reduções aplicadas pelo agendador (Seção IV-F). O treino foi encerrado pela parada antecipada na vigésima quarta época, antes do limite configurado, e o modelo retido corresponde à décima nona época.

A ausência de *overfitting* é coerente com as estratégias adotadas. A normalização em lote e o *dropout*, somados ao *pooling* médio global que mantém o modelo em cerca de 94 mil parâmetros (Seção IV-C), limitam a capacidade de memorização, enquanto o aumento de dados (Seção IV-D) introduz variação a cada época. Cabe notar que a perda de validação permanece abaixo da de treino. Esse comportamento é condizente com este protocolo: o aumento de dados e o *dropout* atuam somente durante o treino, e a amostragem ponderada (Seção IV-E) expõe a rede, no treino, a uma proporção maior das classes minoritárias, ao passo que a validação preserva a distribuição natural do conjunto.

A Fig. 3 apresenta as matrizes de confusão dos dois modelos no conjunto de teste oficial. Cada matriz registra como as 250 amostras de cada classe real foram distribuídas entre as quatro classes preditas, e é dela que derivam as métricas da Tabela IV: a diagonal reúne os acertos, a leitura por linha define o *recall* e a leitura por coluna, a precisão.

A rede convolucional supera a abordagem clássica por uma margem ampla e consistente: a acurácia passa de 0,636 para 0,938, o F1 macro de 0,63 para 0,94 e a AUC macro de 0,864 para 0,994. A vantagem não se concentra em uma única condição, pois o F1 da rede é superior nas quatro classes. Essa diferença é coerente com a natureza dos descritores. O HOG resume orientações locais de gradiente sobre uma grade fixa e privilegia, portanto, a geometria dos contornos; representa mal

Tabela IV
DESEMPENHO NO CONJUNTO DE TESTE OFICIAL. COMO O CONJUNTO É BALANCEADO, A ACURÁCIA COINCIDE COM A ACURÁCIA BALANCEADA.

Classe	HOG + Reg. Logística			CNN Compacta		
	Prec.	Rec.	F1	Prec.	Rec.	F1
CNV	0,53	0,78	0,63	0,84	0,98	0,90
DME	0,63	0,60	0,61	0,96	0,99	0,97
Drusas	0,66	0,43	0,52	1,00	0,80	0,89
Normal	0,80	0,73	0,76	0,98	0,98	0,98
Média macro	0,65	0,64	0,63	0,95	0,94	0,94
Acurácia	0,636			0,938		
AUC macro (OvR)	0,864			0,994		


os padrões de textura e intensidade associados ao acúmulo de fluido, cuja posição varia entre exames. A rede, ao aprender os filtros diretamente dos B-scans, combina contorno, textura e contexto espacial, o que se reflete sobretudo no DME, cujo F1 salta de 0,61 para 0,97.

Drusas é a classe mais difícil para ambos os modelos e concentra o mesmo modo de erro. Na rede convolucional, o comportamento é assimétrico: a precisão é 1,00, ou seja, nenhuma amostra de outra classe recebe o rótulo de drusas, mas o *recall* é 0,80. A Fig. 3(b) mostra que, das 50 drusas não recuperadas, 45 são classificadas como CNV, fluxo que explica a menor precisão da rede justamente na CNV (0,84), apesar do *recall* de 0,98. O mesmo padrão, amplificado, ocorre na regressão logística com extratores HOG: das 250 drusas, apenas 108 são recuperadas e 86 migram para a CNV (Fig. 3(a)). A confusão é clinicamente plausível, pois drusas e CNV pertencem ao mesmo espectro da DMRI, sendo as drusas o achado da forma inicial e a CNV a manifestação neovascular avançada; casos intermediários exibem alterações sutis sob as camadas externas da retina. Contribui ainda o fato de drusas ser a classe minoritária no treino (Tabela II): a amostragem ponderada equaliza a frequência das classes nos lotes, mas o faz repetindo as mesmas imagens, sem acrescentar variabilidade.


Na mesma partição de teste, a rede compacta alcança 93,8% de acurácia, ante os 96,6% relatados por Kermany et al. [1] com uma Inception V3 pré-treinada no ImageNet. A diferença de 2,8 pontos percentuais é obtida com cerca de 94 mil parâmetros, contra aproximadamente 23 milhões, e sem qualquer transferência de aprendizado. O valor também se aproxima dos 94,5% da LightOCT [11], outra arquitetura compacta treinada do zero, o que reforça a viabilidade de modelos reduzidos neste domínio. Resultados obtidos na versão 2 do conjunto, como o de Arefin et al. [12], não constituem referência equivalente, pois aquela partição apresenta sobreposição de sujeitos entre treino e teste [13].

REFERÊNCIAS

- [1] D. S. Kermany, M. Goldbaum, W. Cai *et al.*, “Identifying medical diagnoses and treatable diseases by image-based deep learning,” *Cell*, vol. 172, no. 5, pp. 1122–1131.e9, 2018.



(a) HOG + Regressão Logística



(b) Rede Convolutacional Compacta

Figura 3. Matrizes de confusão no conjunto de teste oficial (1.000 B-scans, 250 por classe): (a) HOG com regressão logística e (b) rede convolutacional compacta. As linhas correspondem à classe real e as colunas, à classe predita.

- [2] Comissão Nacional de Incorporação de Tecnologias no Sistema Único de Saúde, “Medicamentos para tratamento de pacientes com doença ocular que pode levar à cegueira são incorporados ao SUS,” Ministério da Saúde. Disponível em: gov.br/conitec, 2021, acesso em: 10 jul. 2026.
- [3] D. Huang, E. A. Swanson, C. P. Lin, J. S. Schuman, W. G. Stinson, W. Chang, M. R. Hee, T. Flotte, K. Gregory, C. A. Puliafito, and J. G. Fujimoto, “Optical coherence tomography,” *Science*, vol. 254, no. 5035, pp. 1178–1181, 1991.
- [4] B. E. Bouma, J. F. de Boer, D. Huang *et al.*, “Optical coherence tomography,” *Nature Reviews Methods Primers*, vol. 2, p. 79, 2022.
- [5] D. Kermany, K. Zhang, and M. Goldbaum, “Large dataset of labeled optical coherence tomography (OCT) and chest X-ray images,” Mendeley Data, version 3, 2018, licença CC BY 4.0.
- [6] Instituto Brasileiro de Geografia e Estatística, *Pesquisa Nacional de Saúde: 2019: ciclos de vida: Brasil*. Rio de Janeiro, Brasil: IBGE, 2021, acesso em: 11 jul. 2026. [Online]. Available: <https://www.ibge.gov.br/biblioteca/visualizacao/livros/liv101846.pdf>
- [7] S. R. Salomão, R. W. Cinoto, A. Berezovsky, A. Araújo-Filho, M. R. K. H. Mitsuhiro, L. Mendieta, P. H. A. Morales, G. P. Pokharel, R. Belfort Jr., and L. B. Ellwein, “Prevalence and causes of vision impairment and blindness in older adults in Brazil: the São Paulo Eye Study,” *Ophthalmic Epidemiology*, vol. 15, no. 3, pp. 167–175, 2008.
- [8] T. A. Chagas, M. A. dos Reis, G. Leivas, L. P. Santos, A. N. Gosseheimer, G. B. Melo, F. K. Malerbi, and B. D. Schaan, “Prevalence of diabetic retinopathy in Brazil: a systematic review with meta-analysis,” *Diabetology & Metabolic Syndrome*, vol. 15, no. 1, p. 34, 2023.
- [9] J. De Fauw, J. R. Ledsam, B. Romera-Paredes *et al.*, “Clinically applicable deep learning for diagnosis and referral in retinal disease,” *Nature Medicine*, vol. 24, no. 9, pp. 1342–1350, 2018.
- [10] P. P. Srinivasan, L. A. Kim, P. S. Mettu, S. W. Cousins, G. M. Comer, J. A. Izatt, and S. Farsiu, “Fully automated detection of diabetic macular edema and dry age-related macular degeneration from optical coherence tomography images,” *Biomedical Optics Express*, vol. 5, no. 10, pp. 3568–3577, 2014.
- [11] A. Butola, D. K. Prasad, A. Ahmad, V. Dubey, D. Qaiser, A. Srivastava, P. Senthilkumaran, B. S. Ahluwalia, and D. S. Mehta, “Deep learning architecture LightOCT for diagnostic decision support using optical coherence tomography images of biological samples,” *Biomedical Optics Express*, vol. 11, no. 9, pp. 5017–5031, 2020.
- [12] R. Arefin, M. D. Samad, F. A. Akyelken, and A. Davanian, “Non-transfer deep learning of optical coherence tomography for post-hoc explanation of macular disease classification,” in *2021 IEEE 9th International Conference on Healthcare Informatics (ICHI)*, 2021, pp. 48–52.
- [13] I. E. Tampu, A. Eklund, and N. Haj-Hosseini, “Inflation of test accuracy due to data leakage in deep learning-based classification of OCT images,” *Scientific Data*, vol. 9, p. 580, 2022.